

REPORT ECONOMICO

Sistema di Controllo Intelligente del Traffico
Architettura Multi-Agent con Large Language Models (LLM)

Analisi dei costi operativi, infrastrutturali e di mantenimento

Documento Tecnico-Economico per lo Scale-up Urbano

Raffaele Neri - Matteo Melotti - Marco Crisafulli

1. Introduzione e Obiettivi del Report

Il presente report analizza i costi operativi e di mantenimento dell'infrastruttura sviluppata per il sistema di controllo intelligente del traffico, basato su un'architettura multi-agent e Large Language Models (LLM). L'obiettivo è fornire una visione economica completa, trasparente e verificata di tutti i componenti del sistema, con proiezioni scalabili a diversi scenari di deployment.

L'infrastruttura integra componenti distribuiti eterogenei, tra cui:

- **Cluster Kubernetes:** Orchestrazione dei pod e dei servizi distribuiti.
- **Servizi di Orchestrazione:** MCP Server per la comunicazione inter-agent.
- **Simulation Engine SUMO:** Simulazione del flusso veicolare urbano.
- **Moduli di Reasoning:** Utilizzo di API LLM per decisioni adattive.
- **Computer Vision:** Sistema distribuito sugli incroci semaforici.

Il report analizza quattro macro-aree: Spese Software, Spese Hardware, Totale Costi e Stima sulla città di Bologna.

2. Spese Software - Infrastruttura Cloud e Kubernetes

Questa sezione analizza i costi operativi mensili dell'infrastruttura software necessaria per eseguire il sistema multi-agent in ambiente cloud o on-premise. L'obiettivo è valutare come i costi evolvano al crescere del numero di agenti AI attivi simultaneamente all'interno della piattaforma.

2.1. Voci di Costo Dettagliate

Il costo operativo complessivo dell'infrastruttura è composto da diverse componenti software e infrastrutturali, ciascuna caratterizzata da una diversa dinamica di crescita rispetto al numero di agenti distribuiti.

Componente	Descrizione	Comportamento
VM / Cluster K8s	Costo del cluster Kubernetes necessario per eseguire pod e servizi distribuiti	Scala quasi lineare
Agent + Orchestrator Pod	Pod dedicati agli agenti AI e all'orchestratore centrale; inclusi nel cluster Kubernetes	Incluso
Backend + MCP	Servizi backend REST/gRPC e MCP Server per comunicazione inter-agent	Scala moderata
Storage + DB + Logs	Database operativo, logging e storico dati di traffico	Scala moderata
Networking + SSE	Traffico di rete interno, API e stream SSE tra componenti	Scala bassa
Simulazioni SUMO	Costo computazionale delle simulazioni del traffico distribuite	Scala lineare
Costi LLM	Consumo token API LLM per il reasoning distribuito	Scala lineare
Scalabilità Extra	Overhead infrastrutturale dovuto all'incremento del numero di agenti	Scala sub-lineare

2.2. Proiezione dei Costi Mensili

La seguente tabella mostra una stima dei costi mensili al variare del numero di agenti AI distribuiti nel sistema.

Agenti	K8s	Back.	Stor.	Net.	SUMO	LLM	Totale
10	40 €	10 €	10 €	3 €	10 €	80 €	~ 158 €
20	80 €	15 €	15 €	5 €	20 €	250 €	~ 395 €
50	180 €	25 €	25 €	10 €	40 €	1000 €	~ 1300 €
100	350 €	40 €	40 €	20 €	80 €	4000 €	~ 4575 €

2.2.1 Giustificazione delle Stime Economiche

Le stime riportate nella tabella precedente sono state ottenute combinando:

- pricing ufficiali delle API LLM;
- consumo token reale dei prompt agentici;
- requisiti infrastrutturali Kubernetes;
- overhead di networking e orchestrazione distribuita.

Per quanto riguarda i costi LLM, le stime sono basate sui prezzi ufficiali dei modelli OpenAI GPT-4o Mini, pari a circa:

0.15 USD / milione token input

e

0.60 USD / milione token output

come riportato nella documentazione ufficiale OpenAI API Pricing.

Il sistema multi-agent utilizza prompt complessi contenenti:

- topologie locali;
- stato traffico;
- storico stress;
- reasoning orchestrativo;
- tool calling MCP;
- output JSON strutturati.

Il prompt orchestrativo principale (`orchestrator_police.py`) richiede mediamente:

2000–6000 token per ciclo

mentre ogni agente locale utilizza circa:

800–2500 token

per ogni decisione.

In scenari con 50 agenti attivi e reasoning continuo ogni 60 secondi, il sistema può superare:

6 miliardi di token/mese

generando costi operativi LLM compresi tra:

1000–4000 €/mese

Le stime Kubernetes derivano invece da configurazioni cloud standard con:

- VM da 2 vCPU e 4GB RAM;
- pod distribuiti per agenti e orchestratore;
- networking intra-cluster;
- storage persistente e logging continuo.

Le simulazioni SUMO e i servizi backend introducono costi più contenuti, poiché utilizzano container lightweight e componenti centralizzati condivisi tra tutti gli agenti.

Nel complesso, i valori riportati rappresentano uno scenario realistico di utilizzo continuo 24/7 dell'infrastruttura urbana distribuita.

2.3. Stima Numerica dei Costi LLM su Utilizzo Continuo

La stima dei costi LLM è stata calcolata simulando un funzionamento continuo dell'infrastruttura per 30 giorni consecutivi, con agenti e orchestratore sempre attivi.

Il prompt orchestrativo principale (`PROMPT_MCP`) utilizza mediamente:

2000 – 6000 token per ciclo

considerando:

- system prompt;
- output agenti;
- storico stress;
- tool calling MCP;
- risposta JSON finale.

Ogni Traffic Agent utilizza invece mediamente:

800 – 2500 token per decisione

Supponendo uno scenario operativo realistico con:

- 50 agenti attivi;
- 1 decisione ogni 60 secondi;
- 3000 token medi complessivi per agente;
- orchestratore eseguito ad ogni step.

Il consumo totale risulta:

$50 \times 3000 = 150000$ token/minuto

Su base oraria:

$150000 \times 60 = 9$ milioni token/ora

Su base giornaliera:

$9 \times 24 = 216$ milioni token/giorno

Infine, su un mese di utilizzo continuo:

$216 \times 30 = 6480$ milioni token/mese

ovvero circa:

6.5 miliardi di token/mese

Assumendo un costo API medio compreso tra:

0.15–0.60 USD/*milionetoken*

il costo operativo mensile stimato diventa:

1000–4000 €/mese

in scenari con utilizzo continuo 24/7 e carico urbano elevato.

I valori utilizzati risultano coerenti con i pricing ufficiali OpenAI GPT-4o Mini pubblicati nella documentazione API ufficiale.

Questa simulazione rappresenta volutamente uno scenario conservativo ad alto utilizzo. In deployment reali i costi possono essere ridotti tramite:

- aumento dell'intervallo decisionale;
- riduzione dello storico nei prompt;
- compressione delle topologie;
- utilizzo di modelli locali o LiteLLM;
- batching delle decisioni orchestrate.

2.4. Commento e Analisi della Scalabilità

L'analisi economica evidenzia come l'infrastruttura mantenga una buona sostenibilità operativa anche in scenari urbani estesi con numerosi agenti distribuiti.

La crescita dei costi non è completamente proporzionale al numero di agenti, poiché molte componenti centrali vengono condivise tra tutti i servizi dell'architettura. Questo consente di ottenere economie di scala soprattutto per backend, storage, networking e orchestrazione.

La componente economicamente dominante diventa progressivamente il consumo LLM. Ogni agente esegue reasoning distribuito, tool calling MCP e analisi del traffico locale, mentre l'orchestratore globale mantiene sincronizzazione, trend analysis e coordinamento strategico tra tutti gli agenti attivi.

Il costo LLM cresce quindi principalmente in funzione di:

- numero di agenti;
- frequenza delle decisioni;
- lunghezza del contesto;
- numero di tool call;
- complessità della simulazione urbana.

Nonostante ciò, l'architettura utilizza topologie compatte, comunicazione asincrona e reasoning geograficamente distribuito per limitare il consumo complessivo di token.

Nel complesso, il sistema risulta economicamente sostenibile anche in deployment di larga scala, soprattutto utilizzando strategie di ottimizzazione prompt oppure modelli locali compatibili OpenAI tramite LiteLLM o LM Studio.

3. Spese Hardware - Infrastruttura di Computer Vision

Ogni incrocio richiede hardware locale per l'inferenza AI edge, riducendo latenza e costi cloud.

3.1. Dettaglio Costi per Singolo Incrocio

- Telecamera AI Outdoor (IP66): 250 €
- Edge Device AI (NVIDIA Jetson / mini PC): 450 €
- Installazione hardware (montaggio e cablaggio): 300 €
- Alimentazione e rete (switch PoE / LTE): 150 €

Costo Acquisizione per Singolo Incrocio: 1.150 €

A questo si aggiunge un **Server centrale GPU** (costo fisso condiviso) di **4.000 €**.

3.2. Formule di Stima Economica

$$\text{Costo Acquisizione}(n) = n \times 1.150 \text{ €} + 4.000 \text{ €} \quad (1)$$

$$\text{Costo Mensile Mantenimento}(n) = n \times 30 \text{ €} + 20 \text{ €} \quad (2)$$

3.3. Commento e Analisi dell'Infrastruttura Hardware

L'infrastruttura hardware rappresenta la componente fisica necessaria per trasformare il sistema da ambiente simulato a piattaforma operativa reale distribuita sul territorio urbano.

Ogni incrocio necessita di dispositivi dedicati per acquisire ed elaborare dati sul traffico in tempo reale. La scelta di utilizzare edge computing consente di eseguire parte dell'inferenza AI direttamente vicino alla sorgente dei dati, riducendo la latenza decisionale e limitando il traffico verso il cloud centrale.

La componente più costosa del singolo nodo è rappresentata dall'edge device AI, come NVIDIA Jetson o mini PC industriali, necessario per eseguire algoritmi di computer vision e pre-processing locale dei flussi video. A questa si aggiungono telecamere outdoor certificate per ambienti urbani, costi di installazione fisica e infrastruttura di rete.

Il server GPU centrale costituisce invece una risorsa condivisa dell'intero sistema e viene utilizzato per:

- orchestrazione globale;
- storage centralizzato;
- inferenza avanzata;
- gestione del reasoning LLM.

Dal punto di vista economico, il costo di acquisizione cresce in modo quasi lineare rispetto al numero di incroci monitorati. Tuttavia, la presenza di componenti condivisi consente di ridurre il costo medio per nodo nei deployment più estesi.

Anche i costi di mantenimento rimangono relativamente contenuti rispetto a infrastrutture tradizionali di traffic management, grazie all'utilizzo di hardware edge distribuito e servizi software containerizzati.

4. Totale Costi e Proiezioni di Scale-up

Questa sezione consolida i costi hardware di acquisizione e i costi operativi mensili dell'infrastruttura, mostrando come il sistema evolva economicamente al crescere del numero di incroci monitorati.

L'obiettivo è valutare la sostenibilità economica dello scale-up urbano considerando sia l'investimento iniziale (CAPEX) sia i costi di mantenimento continuativi (OPEX).

4.1. Costo di Acquisizione Hardware

Il costo di acquisizione comprende tutti i componenti necessari per l'installazione dell'infrastruttura edge AI presso gli incroci monitorati:

- telecamere AI outdoor;
- edge device per inferenza locale;
- cablaggio e installazione;
- alimentazione e networking;
- server GPU centrale condiviso.

Incroci (n)	Costo Acquisizione	Formula
10	15.500 €	$10 \times 1.150 + 4.000$
20	27.000 €	$20 \times 1.150 + 4.000$
50	61.500 €	$50 \times 1.150 + 4.000$
100	119.000 €	$100 \times 1.150 + 4.000$

La crescita del costo hardware risulta quasi lineare poiché la maggior parte delle componenti viene replicata fisicamente per ogni incrocio monitorato.

4.2. Costo Mensile di Mantenimento

Il costo operativo mensile include:

- manutenzione hardware;
- alimentazione edge device;
- networking;

- monitoraggio;
- aggiornamenti software;
- supporto operativo di base.

Incroci (n)	Costo Mensile	Formula
10	320 €/mese	$10 \times 30 + 20$
20	620 €/mese	$20 \times 30 + 20$
50	1.520 €/mese	$50 \times 30 + 20$
100	3.020 €/mese	$100 \times 30 + 20$

La componente variabile principale è rappresentata dalla manutenzione dei dispositivi edge installati sugli incroci.

La quota fissa di 20 €/mese rappresenta il costo minimo condiviso per storage, logging, backup e monitoraggio centralizzato del sistema.

4.3. Analisi Economica dello Scale-up

Le proiezioni mostrano come il sistema mantenga una buona sostenibilità economica anche in deployment urbani estesi.

Il costo di acquisizione cresce principalmente a causa dell'infrastruttura edge distribuita. Ogni nuovo incrocio richiede infatti:

- nuovi dispositivi di computer vision;
- unità edge AI;
- installazione fisica;
- connettività dedicata.

Il server GPU centrale rappresenta invece un costo condiviso tra tutti gli incroci. Questo consente di ridurre progressivamente il costo medio per nodo all'aumentare della dimensione del deployment.

Anche i costi mensili di mantenimento crescono in modo relativamente controllato, grazie alla presenza di:

- servizi software centralizzati;
- orchestrazione Kubernetes condivisa;
- backend unico;
- orchestratore globale condiviso.

L'architettura proposta risulta quindi particolarmente adatta a uno scale-up progressivo: il sistema può essere inizialmente deployato su un numero ridotto di incroci pilota e successivamente esteso a deployment urbani più ampi senza modificare radicalmente la struttura infrastrutturale.

Nel complesso, il modello economico combina:

- costi fissi condivisi;
- componenti edge modulari;
- servizi software scalabili;
- orchestrazione distribuita.

Questo approccio permette di mantenere elevata la flessibilità operativa limitando al tempo stesso la crescita dei costi infrastrutturali.

5. Stima Economica: Applicazione alla Città di Bologna

Questa sezione applica il modello economico sviluppato nelle sezioni precedenti a uno scenario urbano realistico, utilizzando la città di Bologna come caso studio per valutare la sostenibilità economica di un deployment progressivo del sistema multi-agent.

La simulazione considera differenti livelli di copertura della rete semaforica urbana, partendo da un progetto pilota limitato fino ad arrivare a una configurazione distribuita su larga scala.

5.1. Ipotesi del Modello

La stima economica è stata costruita utilizzando le seguenti ipotesi architetturali e operative:

- 1 agente AI ogni 3 incroci monitorati;
- costo hardware edge pari a 1.150 € per incrocio;
- server GPU centrale condiviso (costo fisso unico di 4.000 €);
- infrastruttura Kubernetes scalabile;
- costi LLM inclusi nei costi AI operativi;
- mantenimento mensile hardware calcolato come $n \times 30 \text{ €} + 20 \text{ €}$.

Il modello considera un utilizzo continuo dell'infrastruttura durante tutto l'anno, includendo orchestrazione distribuita, reasoning LLM, backend persistente e monitoraggio real-time del traffico urbano.

Il Totale del Primo Anno è calcolato come:

$$\text{Totale 1° Anno} = \text{Costo CV} + \text{OPEX Annuale AI} + (\text{Mantenimento Mensile HW} \times 12) \quad (3)$$

5.2. Tabella di Stima Economica

Scenario	Incroci	Agenti	Costo CV	OPEX AI	Mant. HW	Totale 1° Anno
Progetto Pilota	20	7	27.000 €	1.800 €	7.440 €	36.240 €
Area Urbana Centrale	50	17	61.500 €	15.600 €	18.240 €	95.340 €
Copertura Ampia	100	34	119.000 €	31.200 €	36.240 €	186.440 €
Copertura Estesa	150	50	176.500 €	46.800 €	54.240 €	277.540 €

Tabella 1: Stima economica del deployment progressivo del sistema multi-agent sulla rete semaforica urbana di Bologna.

5.3. Commento e Analisi dello Scale-up Urbano

Le stime mostrano come il sistema possa essere introdotto progressivamente all’interno della rete urbana senza richiedere investimenti immediati su larga scala.

Nel caso del progetto pilota da 20 incroci, il costo complessivo del primo anno si attesta a circa 36.240 €, includendo l’acquisizione dell’infrastruttura di computer vision, i costi operativi AI e il mantenimento hardware annuale. Questo consente di validare il comportamento dell’infrastruttura in ambiente reale, verificando stabilità operativa, qualità del reasoning distribuito e impatto effettivo sulla congestione urbana.

Questa fase iniziale permette inoltre di raccogliere dati reali sul traffico e ottimizzare progressivamente le strategie agentiche prima di procedere verso una copertura cittadina più estesa.

All’aumentare del numero di incroci cresce principalmente il costo hardware legato ai dispositivi edge distribuiti sul territorio. Tuttavia, molte componenti software restano condivise tra tutti gli agenti del sistema, tra cui:

- orchestratore globale;
- backend FastAPI;
- MCP Server;
- cluster Kubernetes;
- storage centralizzato.

L’incremento dell’OPEX annuale è invece principalmente dovuto:

- al maggiore consumo di token LLM;
- all’aumento del numero di agenti attivi;
- alla crescita del traffico intra-cluster;
- all’esecuzione continua delle simulazioni distribuite.

La configurazione da 150 incroci rappresenta uno scenario urbano avanzato, in grado di coprire una porzione significativa della rete semaforica della città di Bologna. Nonostante l'aumento del carico computazionale e del numero di agenti distribuiti, il costo complessivo rimane competitivo rispetto ai tradizionali sistemi proprietari di traffic management.

L'utilizzo di componenti open-source, orchestrazione Kubernetes e servizi containerizzati consente inoltre di evitare lock-in tecnologici e ridurre sensibilmente i costi di licenza software nel lungo periodo.

Nel complesso, il modello economico proposto dimostra come l'architettura multi-agent possa essere scalata progressivamente mantenendo un buon equilibrio tra costi operativi, modularità infrastrutturale e capacità di gestione dinamica del traffico urbano.

6. Reliability, Cost and ROI Analysis

Questa sezione analizza affidabilità, sostenibilità economica e ritorno sull'investimento dell'architettura multi-agent proposta. L'obiettivo è valutare se le scelte tecniche adottate siano giustificate anche dal punto di vista economico e operativo.

6.1. Service Level Objectives (SLOs)

Gli obiettivi di servizio definiti per il sistema mirano a garantire continuità operativa, risposta real-time e stabilità dell'infrastruttura distribuita.

Metrica	Obiettivo Stimato
Disponibilità sistema	99.5%
Latenza media agenti	< 3 secondi
Tempo sincronizzazione orchestrator	< 5 secondi
Successo esecuzione MCP tool	> 99%
Aggiornamento stato traffico	1 secondo

Tali valori sono compatibili con un sistema urbano distribuito che deve reagire rapidamente alle variazioni del traffico, mantenendo continuità operativa e coordinamento tra agenti locali e orchestratore globale.

6.2. Costo Stimato di un'Ora di Downtime

Un'interruzione completa del sistema potrebbe causare degrado nella gestione del traffico urbano, con effetti diretti sulla mobilità cittadina. La stima di circa 4.000 €/ora considera ritardi accumulati dagli utenti, aumento della congestione e perdita temporanea delle funzionalità di monitoraggio e controllo adattivo.

Voce di impatto	Costo stimato
Ritardi e tempi di percorrenza aggiuntivi	1.500 €/ora
Congestione e inefficienza della rete urbana	2.000 €/ora
Perdita monitoraggio e controllo adattivo	500 €/ora
Totale stimato	4.000 €/ora

Il valore non rappresenta una perdita diretta del software, ma una stima dell’impatto operativo sulla mobilità urbana. In assenza del controllo intelligente, i semafori tornerebbero a una gestione meno adattiva, aumentando la probabilità di code, ritardi e inefficienze.

6.3. Investimenti in Resilienza e Ridondanza

Per ridurre il rischio di downtime totale, si propone un investimento mirato in resilienza infrastrutturale. La soluzione include replica dei pod Kubernetes, restart automatico dei container, monitoring continuo, orchestrator ridondante e backend persistente replicato.

Costo aggiuntivo stimato: 80–120 €/mese

L’investimento è giustificato perché riduce i single point of failure e aumenta la continuità operativa del sistema, con un costo contenuto rispetto all’impatto economico potenziale di un’ora di downtime.

6.4. Costo Operativo Mensile Stimato

I costi operativi mensili crescono con il numero di agenti attivi e con la frequenza di reasoning. Dopo l’aggiornamento delle stime LLM su utilizzo continuo, la voce più rilevante diventa il consumo token generato dagli agenti e dall’orchestratore.

Scala Deployment	Costo Mensile Stimato
10 agenti	~ 150–200 €/mese
50 agenti	~ 1.300 €/mese
100 agenti	~ 4.500 €/mese

Questi valori includono cluster Kubernetes, backend, MCP Server, storage, networking, simulazioni SUMO e costi LLM. Lo scenario considera utilizzo continuativo dell’infrastruttura, quindi rappresenta una stima prudenziale ad alto carico.

6.5. Agent-Related Cost Ceiling

La componente economicamente più variabile è il reasoning agentico tramite LLM. Il costo dipende da numero di agenti, frequenza decisionale, dimensione dei prompt, storico utilizzato e numero di tool call MCP.

Costo massimo stimato per 100 agenti: circa 4.000–4.500 €/mese

Topologie compatte, comunicazione asincrona, batching delle decisioni e riduzione dello storico possono ridurre il consumo effettivo. Tuttavia, in uno scenario 24/7 con reasoning frequente, il costo LLM rimane la principale voce agent-related.

6.6. Trade-off: Cost vs Reliability

L'aumento della ridondanza migliora affidabilità e continuità operativa, ma comporta un incremento delle risorse necessarie. Più replica significa più pod attivi, maggiore uso di CPU/RAM, più traffico intra-cluster e costi cloud superiori.

L'architettura proposta cerca un compromesso adottando servizi lightweight, scaling dinamico Kubernetes ed esecuzione asincrona. In questo modo si mantiene una buona resilienza senza sovradimensionare eccessivamente l'infrastruttura.

6.7. Trade-off: Automation vs Safety

L'automazione completa del controllo semaforico aumenta reattività e adattività, ma può introdurre rischi legati alla prevedibilità delle decisioni AI. Decisioni troppo aggressive o non coordinate potrebbero generare oscillazioni semaforiche o comportamenti indesiderati.

Per mitigare tali rischi, il sistema utilizza orchestrazione centralizzata, policy configurabili, tool MCP deterministici, limiti sulle azioni degli agenti e possibilità di supervisione umana. Questo permette di mantenere un alto livello di automazione senza compromettere la sicurezza operativa.

6.8. ROI Analysis

Il ritorno sull'investimento viene valutato confrontando i costi di acquisizione e mantenimento con i benefici operativi prodotti dalla gestione intelligente del traffico.

Il valore economico non deriva solo dal risparmio diretto sull'infrastruttura, ma soprattutto dalla riduzione delle inefficienze urbane generate da congestione, ritardi e gestione semaforica non adattiva.

I principali benefici misurabili per il cliente sono:

- riduzione dei tempi medi di attesa agli incroci;
- diminuzione della congestione nelle ore di punta;
- migliore fluidità dei flussi veicolari;
- riduzione dei costi indiretti legati a ritardi, carburante ed emissioni;
- minore necessità di interventi manuali sulla regolazione semaforica.

Il ROI dipende da tre elementi principali:

- **CAPEX:** telecamere, edge device, installazione, server GPU e setup iniziale;
- **OPEX:** Kubernetes, costi LLM, networking, storage, monitoring e manutenzione;

- **Benefici operativi:** riduzione congestione, minori ritardi e migliore utilizzo dell'infrastruttura esistente.

In uno scenario pilota, il ritorno non va valutato solo come recupero immediato dell'investimento, ma come validazione tecnica ed economica del modello. In scenari urbani più estesi, il ROI migliora perché i costi fissi vengono condivisi su più incroci e aumenta la quantità di traffico ottimizzato.

7. Return on Agent (ROA) Assessment

Il Return on Agent valuta se l'introduzione di capacità agentiche produce valore operativo superiore al costo aggiuntivo di reasoning LLM, orchestrazione distribuita e maggiore complessità architetturale.

Nel sistema proposto, l'approccio agentico è giustificato perché il traffico urbano è dinamico, distribuito e soggetto a variazioni continue. Un sistema statico o basato su regole fisse non riesce ad adattarsi con la stessa rapidità a congestioni locali, picchi improvvisi o cambiamenti nei flussi veicolari.

7.1. Valore Operativo degli Agenti

Gli agenti aggiungono valore perché consentono di distribuire il carico decisionale. Ogni agente analizza una porzione locale della rete stradale, mentre l'orchestratore mantiene una visione globale e coordina le strategie complessive.

I principali vantaggi operativi sono:

- decisioni locali più rapide;
- riduzione del carico su un unico controllore centrale;
- coordinamento globale tramite orchestratore;
- migliore scalabilità su reti urbane ampie;
- maggiore reattività a congestioni improvvise.

7.2. Costi e Rischi Agentici

Il costo aggiuntivo degli agenti deriva principalmente dall'utilizzo di LLM, dal tool calling MCP e dalla sincronizzazione tra agenti e orchestratore. A questi costi si aggiunge una maggiore complessità architetturale, che richiede monitoring, logging e meccanismi di fallback.

Tale costo è giustificato soprattutto in scenari con traffico variabile, molte intersezioni e necessità di adattamento continuo. In contesti molto piccoli o con traffico stabile, un sistema statico potrebbe essere economicamente più conveniente.

8. Conclusioni e Raccomandazioni

L'analisi economica sviluppata nel presente report evidenzia come l'architettura multi-agent proposta rappresenti una soluzione sostenibile sia dal punto di vista tecnico che economico per il controllo intelligente del traffico urbano.

Il sistema riesce a combinare scalabilità, modularità e contenimento dei costi grazie all'utilizzo di tecnologie open-source, orchestrazione distribuita tramite Kubernetes e approccio edge computing per la computer vision sugli incroci.

Uno degli aspetti più rilevanti emersi dall'analisi è la possibilità di introdurre il sistema in modo progressivo. L'adozione può infatti partire da piccoli deployment pilota e crescere successivamente senza richiedere modifiche strutturali all'infrastruttura software.

Dal punto di vista operativo, il costo mensile dell'infrastruttura AI risulta relativamente contenuto anche in scenari con decine di agenti attivi. Parallelamente, i costi hardware rimangono compatibili con progetti urbani di digitalizzazione e smart mobility.

L'assenza di licenze proprietarie costituisce inoltre un vantaggio economico significativo nel lungo periodo, riducendo il rischio di lock-in tecnologico e permettendo una maggiore flessibilità evolutiva del sistema.

8.1. Valutazione Economica Complessiva

L'infrastruttura proposta dimostra un buon equilibrio tra investimento iniziale, costi operativi e capacità di scalabilità urbana.

I principali vantaggi economici identificati sono:

- costi operativi relativamente bassi rispetto a piattaforme proprietarie centralizzate;
- possibilità di scalare progressivamente il numero di incroci monitorati;
- riduzione della dipendenza da infrastrutture cloud ad alta intensità computazionale;
- riutilizzo di componenti software condivisi tra più agenti;
- possibilità di contenere il consumo LLM tramite ottimizzazione dei prompt e topologie compatte.

8.2. Raccomandazioni Finali

Sulla base delle analisi effettuate, si raccomanda di:

1. avviare il sistema con un deployment pilota limitato (20 incroci) per validare le prestazioni in ambiente reale;
2. ottimizzare progressivamente il consumo token dei modelli LLM, poiché rappresentano una delle componenti operative più variabili;
3. valutare strategie di edge inference locale per ridurre ulteriormente i costi cloud;
4. prevedere politiche di acquisto hardware su larga scala per ridurre il costo medio per incrocio;
5. mantenere un'architettura modulare e containerizzata per facilitare future estensioni del sistema.

L'architettura proposta offre una soluzione economicamente sostenibile, modularmente scalabile e tecnologicamente avanzata per la gestione intelligente del traffico urbano.